

정치 발언 모순 탐지기

< 개발 계획서 v2 — 모순 탐지 + 팩트체크 />

Political Statement Contradiction & Fact Checker · 2일 해커톤 · 저널리즘 × AI 트랙

스택: Next.js + Claude API (Opus 4.8, 웹검색) + Whisper STT + INSEE(FR)·KOSIS(KR) 통계 API

1. 프로젝트 개요 & 비전

최근 한국·프랑스를 비롯한 여러 나라 정치에서 정치인들이 **과거에 한 말과 현재의 말이 모순되거나, 사실이 아닌 주장**을 하는 경우가 화두이며, 이는 특히 청년층에 큰 불만과 정치 불신을 초래한다. 이 프로젝트는 정치인 발언을 **두 개의 독립된 축**으로 검증한다.

두 개의 검증 축: ① **자기 일관성** — 본인 과거 발언과 어긋나는가(진영·옳고그름 무관, 완전 중립). ② **사실성(팩트체크)** — 그 주장이 실제 사실인가(정부 공식 통계·웹 검색으로 교차검증). 두 축을 **섞지 않고 별도 라벨로** 표기해 중립성을 지킨다.

비전 vs 이번 데모 범위

- **최종 목표(로드맵):** 생방송 정치 프로그램에서 **실시간**으로, 정치인이 말하는 순간 모순·허위를 즉시 잡아내는 프로그램.
- **이번 해커톤(48h) 웹 데모:** 방송 종료 후 **영상 자료를 업로드**하면 발언을 추출하고, ㉠ 과거 발언과 대조해 모순을 탐지하고 **일관성 %**를 계산하며, ㉡ 사실 주장은 **공식 통계·웹으로 팩트체크**해 사실/거짓/검증불가를 출처와 함께 보여준다.

심사 기준 매핑: ① 실제 문제 + 수치 증명 ② 작동하는 핵심 기능 ③ AI 사용 설명. 팩트체크는 초청 기자들이 강조한 "AI 시대의 진위 검증" pain point에 정면으로 대응 → Best Journalism 겨냥.

2. 핵심 기능 (이번 데모)

1. 영상 업로드 → 발언 추출(STT).
2. [축 1] 모순 탐지 — 각 발언을 과거 발언 DB와 대조 → 모순 여부 + 근거·출처·날짜.


3. [축 2] 팩트체크 — 검증 가능한 사실 주장만 골라 Claude 웹검색 + INSEE/KOSIS 공식 통계로 대조 → 사실/거짓/검증불가 + 출처 + 신뢰도.
4. 점수 2종: 일관성 % = (모순 없는 발언/전체)×100, 정확성 % = (사실로 확인된 주장/검증한 주장)×100.
5. 결과 대시보드: 발언별 배지 2개(일관성·사실성) + 카드 + 점수 게이지.


3. 기술 스택

레이어	선택	비고
프론트엔드	Next.js (App Router) + TypeScript + Tailwind	배포까지 한 번에, 때깔 좋은 데모
백엔드	Next.js API Routes + <code>@anthropic-ai/sdk</code>	별도 서버 불필요
STT (영상→텍스트)	OpenAI Whisper API	한국어 지원. Claude엔 STT 없음. 폴백: 대본(.txt/.srt) 직접 업로드
모순 판정 + 점수	<code>claude-opus-4-8</code> · adaptive thinking · structured outputs	추론이 필요한 판정에 적합
팩트체크 엔진	<code>claude-opus-4-8</code> + 웹검색 서버틀 (<code>web_search_20260209</code>)	실시간 검색 + 출처 인용. 범용 사실 검증
권위 통계 소스	INSEE(프랑스) · KOSIS(한국) OpenAPI	통계 주장은 정부 공식 데이터로 교차검증. 무료·API키
데이터	<code>statements.json</code> (과거 발언 20~40개 큐레이션)	임베딩·벡터DB 불필요 — 1M 컨텍스트에 통째로 주입
배포	Vercel (+ 로컬 데모 시 Ngrok)	URL 하나로 무대 데모

확장 로드맵(피치용): 실시간 스트리밍 STT + 라이브 판정, Supabase + Voyage AI 임베딩, 뉴스·국회 API 자동 수집, 통계 소스 국가별 확장.

4. 아키텍처 & 데이터 흐름





STT 리스크 대비 풀백: 영상 대신 대본 텍스트를 바로 API에 투입 → 데모가 절대 안 깨지게.

5. 데이터 모델 (TypeScript)

```
interface Statement {           // 과거 발언 (statements.json)
  id: string; politician: string; text: string;
  date: string; sourceUrl: string; topic: string;
}
interface SpokenLine { text: string; timestamp: number; }

interface ConsistencyVerdict {  // 축1: 모순
  line: string; isContradiction: boolean;
  pastStatement?: string; reason: string; confidence: number;
}
interface FactVerdict {        // 축2: 사실성
  line: string;
  isFactualClaim: boolean;      // 검증 가능한 사실 주장인가
  verdict: "TRUE" | "FALSE" | "UNVERIFIABLE";
  reason: string;
  sources: { title: string; url: string }[];
  sourceType: "INSEE" | "KOSIS" | "WEB";
  confidence: number;
}
interface AnalysisResult {
  politician: string;
  consistency: ConsistencyVerdict[];
  facts: FactVerdict[];
  consistencyScore: number;     // 0~100
  accuracyScore: number;       // 0~100
}
```

6. API 설계

POST /api/transcribe — 영상/오디오 → Whisper → SpokenLine[]

POST /api/analyze — 과거 발언 대조(모순 + 일관성 %) — Opus 4.8 structured output

POST /api/factcheck — 사실 주장 검증. 라우팅: 통계 주장이면 INSEE/KOSIS 조회 후 근거로 판정, 아니면 웹검색.

```
// app/api/factcheck/route.ts (핵심) — 웹검색 서버를 사용
import Anthropic from "@anthropic-ai/sdk";
const client = new Anthropic();
```

```
const res = await client.messages.create({
  model: "claude-opus-4-8",
  max_tokens: 8000,
  thinking: { type: "adaptive" },
  tools: [{ type: "web_search_20260209", name: "web_search" }], // 실시간 검색+출처
  output_config: {
    format: { type: "json_schema", schema: {
      type: "object",
      properties: {
        facts: { type: "array", items: { type: "object", properties: {
          line: { type: "string" },
          isFactualClaim: { type: "boolean" },
          verdict: { type: "string", enum: ["TRUE", "FALSE", "UNVERIFIABLE"] },
          reason: { type: "string" },
          confidence: { type: "number" }
        }, required: ["line", "isFactualClaim", "verdict", "reason", "confidence"],
        additionalProperties: false }},
        accuracyScore: { type: "number" }
      }, required: ["facts", "accuracyScore"], additionalProperties: false }
    },
  },
  messages: [{ role: "user", content: buildFactPrompt(lines, statsContext) } ]
});
```

주의: Opus 4.8은 temperature 등 샘플링 파라미터 넣으면 **400 에러** — 넣지 말 것. 통계 API(INSEE/KOSIS)는 백엔드가 먼저 조회해 statsContext 로 프롬프트에 넣거나, 커스텀 톨로 연동. 인증:

ANTHROPIC_API_KEY · OPENAI_API_KEY · INSEE_KEY · KOSIS_KEY .

7. 프롬프트 설계

[팩트체크 프롬프트]

당신은 신중한 팩트체커다. 규칙:

- 1) 검증 가능한 '사실 주장' (숫자·통계·역사적 사실)만 검증한다.
의견·전망·가치판단("증세가 옳다")은 isFactualClaim=false로 스킵.
- 2) 통계 주장은 제공된 공식 통계(INSEE/KOSIS)를 최우선 근거로 삼고,
없으면 web_search로 신뢰할 수 있는 출처를 찾는다.
- 3) 판정은 TRUE / FALSE / UNVERIFIABLE 셋 중 하나. 역지로 참·거짓 가르치 마라.
- 4) 모든 판정에 근거(reason)와 출처(sources)를 붙이고 confidence(0~1)를 매긴다.
- 5) accuracyScore = (TRUE 판정 수 / 검증한 사실주장 수) × 100.

[제공된 공식 통계] {{stats_context}}

[검증할 발언] {{spoken_lines}}

위 스키마(JSON)로만 답하라.

일관성 프롬프트는 v1과 동일(본인 발언끼리만, 맥락 다르면 모순 아님, 출처·신뢰도).

8. UI / UX

- 흐름: 정치인 선택 → 영상/대본 업로드 → 변환·분석 진행 → 결과 대시보드 → 경고 상태.
- 발언별 배지 2개: ● 일관성(일치/모순) · ● 사실성(사실/거짓/검증불가). 카드 클릭 시 근거·출처·과거발언 펼침.
- 상단 점수 2종 게이지: 일관성 % · 정확성 %.
- 디자인 방향: 깔끔·중립·신뢰. 출처 링크 상시 노출 → "주장"이 아니라 "인용·검증"임을 강조.

9. 2일 개발 타임라인 (오전=Web / 오후=AI)

시점	할 일
Day 1 오전 (Web)	Next.js 스캐폴딩, 업로드 UI + 대시보드(배지 2개·게이지 2개) 스켈레톤, <code>statements.json</code> 큐레이션
Day 1 오후 (AI)	축1 모순 판정 <code>/api/analyze</code> + 일관성 % structured output 검증. 프롬프트 엔지니어링
Day 2 오전	축2 팩트체크 <code>/api/factcheck</code> (웹검색틀) + INSEE·KOSIS 연동, Whisper STT 연동(+대본 폴백), 통합·UI 폴리시
Day 2 오후	Vercel 배포, 데모 리허설, 5분 피치 + 포스터 + 타임라인 비주얼

10. 문제 증명용 수치 (리서치 항목)

- 국내: 한국행정연구원 정부·국회 신뢰도, 통계청 사회조사.
- 글로벌: OECD Trust in Government, Edelman Trust Barometer, Pew Research.

 **주의:** 정확한 최신 수치는 발표 전 원문에서 직접 확인해 인용.

11. AI & 외부 API 사용 설명 (심사 필수)

- STT: Whisper(영상→텍스트).
- 모순 판정 + 점수: Claude Opus 4.8.
- 팩트체크: Claude Opus 4.8 + 웹검색 서버틀.
- 권위 통계 소스: INSEE(프랑스), KOSIS(한국) 정부 공식 OpenAPI.
- 임베딩: 미사용. 최종 검증: 사람 → "AI 초벌, 검증은 인간" 원칙(특히 팩트체크에서 필수).

12. 리스크 & 대응

리스크	대응
정치 편향 논란	본인 발언 대조(중립) + 팩트체크는 출처 기반으로만, 두 축 분리 표기

팩트체크 오픈·명예훼손	검증 가능한 사실만, TRUE/FALSE/ 검증불가 3단계, 출처 상시, 사람 최종 검증
STT 정확도	대본 풀백 + 변환 결과 사람 교정
모순 오탐	맥락 인지 프롬프트 + 신뢰도 + 사람 검증
통계 API 한계	KOSIS 개발계정 1,000건/일(데모 충분). 통계 없으면 웹검색 풀백
API 비용/지연	데이터 크기 제한, 스트리밍, 캐시

13. 데모 & 피치 준비물

- 작동 데모: 영상 업로드 → 모순 + 팩트체크 + 점수 2종.
- 5분 엘리베이터 피치 대본 / 프로젝트 비주얼·포스터 / 캐치한 타임라인.
- **미리 확보:** "말 바꾼" 실제 클립 1~2개 + **검증 잘 되는 통계 주장** 1~2개(INSEE/KOSIS로 명확히 판정되는 것).

14. 개발 환경 세팅

```
npx create-next-app@latest contradiction-detector --typescript --tailwind --app
cd contradiction-detector
npm i @anthropic-ai/sdk openai

# .env.local
ANTHROPIC_API_KEY=sk-ant-...
OPENAI_API_KEY=sk-...      # Whisper STT
INSEE_KEY=...              # portail-api.insee.fr 가입 후 발급
KOSIS_KEY=...              # kosis.kr/openapi 가입 후 발급

npm run dev                # http://localhost:3000
```

15. 검증 방법 (End-to-End)

1. `npm run dev` 후 "말 바꾼" 클립 + 통계 주장 포함 대본 업로드.
2. 축1: 모순 카드가 낱·출처와 함께, 일관성 %가 계산되는지.
3. 축2: 통계 주장이 INSEE/KOSIS 출처로 사실/거짓 판정되고, 애매하면 검증불가로 표시되는지.
4. 맥락 다른 발언·의견은 오탐/무리한 팩트체크 안 하는지(검증불가·해당없음).
5. Vercel 배포 URL에서 동일 작동, 실패 시 Ngrok 풀백.